

Model ewolucyjny w oparciu o Geometryczny Model Fishera (GFM)

Aleksander Janowiak i Maria Prus-Głowacka
ćwiczenie 1 z Biologii systemów

Marzec 2025

1 Wstęp

Geometryczny Model Fishera opisuje adaptację organizmów w zmieniającym się środowisku. Każdy organizm reprezentowany jest jako punkt w wielowymiarowej przestrzeni cech. Optimum fenotypowe jest przedstawione jako punkt w tej przestrzeni. Jego położenie determinuje dostosowanie (fitness) każdego osobnika. Mutacje to losowe przesunięcia, charakteryzujące się różnym kierunkiem i siłą.

W pracy model został rozszerzony. Sukces reprodukcji danego osobnika był losowany z rozkładu dwumianowego, gdzie liczba prób determinowana jest przez fitness osobnika zdolnego do rozrodu. Dodano także wiele optima, a za funkcję fitness przyjęto odległość od najbliższego optimum dla każdego osobnika.

Założeniem modelu było opisanie środowiska, zmieniającego się pod wpływem złożonych procesów selekcji, mutacji i reprodukcji, oraz zaobserwowanie sukcesywnej adaptacji organizmów/populacji do nowych warunków.

2 Wybrane rozszerzenie

2.1 Wiele optimów fenotypowych

Pierwszym rozszerzeniem dodanym do modelu była implementacja wielu optimów. Każde optimum jest reprezentowane osobnym obiektem klasy *Habitat*. Zdecydowano się na dodanie tej klasy ze względu na konieczność zaimplementowania osobnych limitów liczebności populacji dla każdego siedliska.

Dysponując globalnym limitem N osobników w całej populacji, symulacja zachowywała się głupio: gdy w jednym obszarze populacja nagle wybuchała, w innym znikała w sposób nagły i zagadkowy. Każdy obiekt klasy *Habitat* posiada następujące atrybuty:

- *optim* - wektor współrzędnych optimum fenotypowego
- *vector* - wektor kierunkowej zmiany tego siedliska
- *residents* - lista obiektów klasy *Individual*, osobników, dla których to siedlisko jest najbliższe. To właśnie ten atrybut pozwala na obcinanie populacji ze względu na przynależność do konkretnego siedliska.

Nowe siedlisko jest tworzone w równych odstępach czasowych za pomocą funkcji *expand* klasy *Environment*. Zatem, użytkownik steruje częstością dodawania siedlisk za pomocą parametrów *max_num_optims* i *max_generations* pliku konfiguracyjnego. Tworzone optimum fenotypowe jest kopią innego optimum, losowo wybranego spośród istniejących w danym momencie.

Co istotne, obiektowi klasy *Habitat* odpowiadającemu nowo stworzonemu optimum jest nadawany inny, (odpowiednio przeskalowany) losowy wektor kierunkowy. Decyzje projektowe opisane w poprzednich dwóch zdaniach skutkują tym, że użytkownik jest w stanie zaobserwować naturalnie wyglądające "rozchodzenie się" optimum w czasie.

2.2 Schemat reprodukcji

Kolejnym rozszerzeniem była implementacja nowej funkcji rozrodu. Wybrany przez nas schemat reprodukcji polega na losowaniu liczby potomstwa każdego osobnika z rozkładu dwumianowego, w oparciu o odległość od najbliższego optimum fenotypowego tegoż osobnika.

$Liczba\ dzieci \sim Binom(n, p)$, gdzie n jest liczbą szans na rozród, którą dostaje dany osobnik i zależy od przedziału w jakim znajduje się wartość fitness osobnika, a p jest globalnym parametrem symulacji, równym dla wszystkich osobników.

$$P(\text{liczba dzieci} = k) = \binom{n}{k} p^k (1 - p)^{n-k}, \quad k = 0, 1, \dots, n$$


Wprowadziliśmy nowe zmienne, którymi użytkownik może sterować z poziomu *config.py*, są nimi:

- p - prawdopodobieństwo rozrodu w pojedynczej próbie
- *fitness_levels* - wartości graniczne dostosowania, które wyznaczają przedziały szans na rozród dla populacji
- *children_proportion* - lista wartości n , w kolejnych przedziałach dostosowania zdefiniowanych przez parametr *fitness_levels*.

Wprowadzenie stochastyczności do sposobu rozmnażania w pewien sposób modeluje dryf genetyczny. W naszej symulacji, osobniki o identycznym poziomie dostosowania mogą mieć różną liczbę potomstwa, jak również, co mniej prawdopodobne, osobnik gorzej dostosowany może odnieść większy sukces reprodukcyjny niż jego lepiej dostosowany konkurent. Mechanizm ten odzwierciedla rzeczywiste zjawiska ewolucyjne - to czy dana cecha utrwali się w

populacji nie jest zależne tylko od dostosowania osobników, ale również od zdarzeń losowych. Szczególnie w małych populacjach, gdzie dryf genetyczny odgrywa większą rolę, możemy obserwować przypadkowe utrwalanie się cech niekorzystnych, pomimo ich negatywnego wpływu na dostosowanie.

Poniżej przedstawiono wykresy prawdopodobieństwa zdarzenia polegającego na tym, że osobnik znajdujący się w mniej optymalnym obszarze fenotypowym będzie miał więcej potomstwa niż osobnik mający od niego więcej szans na reprodukcję. Na wykresach przedstawiono scenariusze dla różnych wyborów n_1 i n_2 , w zależności od zmieniającej się wartości p .



Rysunek 1: Wykresy prawdopodobieństwa odniesienia większego sukcesu reprodukcyjnego przez osobnika o mniejszej liczbie szans na rozród

Można zauważyć, że w okolicach $p = 0.2$ na każdym z wykresów znajdują się szczyty prawdopodobieństwa zajścia rozważanego zdarzenia (wartość ta jest charakterystyczna dla wybranych n_1 i n_2). W dalszych częściach raportu wartość p maksymalizująca to prawdopodobieństwo jest oznaczana jako p_{max} .

Oczywiście, dzieje się też czasami tak, że gorzej dostosowany osobnik zdominuje lepiej dostosowanego, gdy oba te osobniki znajdują się w tym samym przedziale dostosowania. Jest to dosyć częste: przy $n = 1$ dla dowolnych dwóch osobników dzieje się to z prawdopodobieństwem $\frac{1}{4}$, które dąży do $\frac{1}{2}$ gdy $n \rightarrow \infty$. Nie jest to zbyt ciekawe zjawisko, i z pewnością nie zasługuje na własny wykres, ale warto pamiętać, że nasz model ma też taką właściwość - dyskretnie zmieniająca się liczba szans na rozród wprowadza kolejny rodzaj fluktuacji, nieobecny gdy szanse reprodukcji zmieniają się w sposób ciągły (jak na przykład w modelu proporcjonalnym).

2.3 Zmiana organizacji kodu

Struktura głównej pętli programu *main.py* została przeorganizowana w taki sposób, aby wyciąganie wniosków z oglądania symulacji klatka po klatce miało więcej sensu. Miało to na

celu ułatwienie zarówno analizy własności symulacji jak i debugowanie kodu.

Jednym z problemów w bazowej implementacji *GFM* było to, że pomiędzy stworzeniem aktualnej klatki wizualizacji a kolejną reprodukcją osobnik mutował, czyli mógł np. wyskoczyć z danego przedziału dostosowania i mieć inną liczbę szans na reprodukcję niż wynika z obrazka.

Sposób działania naszej pętli w pliku *main.py* zapewnia, że to co widzimy w danej klatce wizualizacji jest dokładnie tym co wchodzi do następnej iteracji symulacji. W celu osiągnięcia takiego efektu, zmieniono m.in. liczbę i rozstawienie selekcji progowych oraz ograniczono liczbę mutacji populacji do 1 na generację. Pojęliśmy decyzję, że osobnik nie mutuje w trakcie życia, jedynie przy narodzinach (jest to całkiem sensowne z punktu widzenia biologii).

3 Analiza wyników symulacji

3.1 Analiza wpływu parametrów mutacji i selekcji

Przeprowadzono serię symulacji z różnymi parametrami *sigma* oraz *mutation_rate* i zmierzono średnie odchylenie standardowe dostosowania oraz średnie dostosowanie co przedstawiono na poniższych mapach ciepła. Aby przetestować czy wprowadzony schemat reprodukcji wpływa na zmienność dostosowania, przeprowadzono dwie pary symulacji: dla $p = 1$ oraz dla $p = p_{max}$. We wszystkich prowadzonych symulacjach obecne było jedno optimum fenotypowe a *children_proportion* = [2, 3]. W tych warunkach p_{max} wyniosło 0.2973


Wartości pozostałych stałych parametrów wykorzystane w tych symulacjach: *max_num_optims* = 1, $N = 200$, *fitness_levels* = [0.5, 0.95], *max_generations* = 100, *delta* = 0.05, *threshold* = 0.5, *mu_c* = 0.5, *xi* = 0.3.

Dla zachowania czytelności wykresów gradienty skal zostały dopasowane do poszczególnych zmiennych.


Jak widać na obu wykresach, wartość średniego dostosowania osobników jest odwrotnie proporcjonalna do odchylenia standardowego fitnessu, niezależnie od wartości p . Tak samo, niezależnie od wartości p średnie dopasowanie rośnie wraz ze wzrostem wartości *mutation_rate* oraz *sigma*. Jednak dla $p = p_{max}$ rozrzut wartości dla obydwu wykresów jest znacznie większy. Możemy zatem powiedzieć, że parametr p wpływa na dostosowanie osobników w sposób zgodny z naszą intuicją o dryfie genetycznym.

3.2 Analiza wpływu parametrów mutacji i zmian środowiska

W tej sekcji realizowany jest podpunkt zadania mówiący o zaprojektowanych scenariuszach zmian środowiska. Zdecydowaliśmy się na modelowanie ocieplenia klimatu, gdyż ten scenariusz wykorzystuje mechanizm przesuwania optimum pomiędzy generacjami w sposób kierunkowy - mechanizm, który i tak istnieje w naszym programie.




Rysunek 2: Wykres prawdopodobieństwa odniesienia większego sukcesu reprodukcyjnego przez osobnika o mniejszej liczbie szans na rozród dla $children_proportion = [2, 3]$



Rysunek 3: Mapy ciepła średniej i odchylenia standardowego fitness w symulacjach prowadzonych przy $p = 1$

Globalne ocieplenie, oprócz wpływu na temperaturę zmienia środowisko na wiele innych, trudnych do przewidzenia sposobów. Wraz z ocieplającym się klimatem, częstsze stają się susze i powodzie, zmienia się także wzór cyrkulacji atmosferycznej i prądów morskich. Takie zamiany powodują migracje wielu organizmów co skutkuje przesuwaniem się niszy ekologicznych i powstaniem nowych interakcji międzygatunkowych.


Chaotyczne zmiany ekosystemów zdecydowaliśmy się zamodelować poprzez powstawanie nowych optimów fenotypowych w czasie i rozchodzenie się tychże optimów w losowych kierunkach.



Rysunek 4: Mapy ciepła średniej i odchylenia standardowego fitness w symulacjach prowadzonych przy $p = p_{max}$

Przeprowadzono szereg symulacji dla różnych długości wektora przesunięcia kierunkowego (c), co miało odpowiadać różnemu nasileniu zmian klimatu, oraz dla różnych wartości siły mutacji (ξ), aby zobaczyć czy silniej mutujące populacje są w stanie nadążyć za tempem zmian otoczenia.


Parametry symulacji dobrano tak samo jak przy poprzednich analizach, zmieniono tylko max_num_optims , które ustawiono na 5. Z oczywistych powodów trzeba było wybrać też wartości mu oraz $sigma$, zdecydowano się na następującą parę liczb dla wszystkich symulacji: $sigma = 0.5$, $mu = 0.5$. Tak samo jak poprzednio, stworzono dwie pary map ciepła: dla $p = 1$ oraz dla $p = p_{max}$ (wciąż równego 0.2973) aby zobaczyć czy schemat reprodukcji odgrywa rolę w tym scenariuszu.



Rysunek 5: Mapy ciepła średniej i odchylenia standardowego fitness w symulacjach prowadzonych przy $p = 1$

Jak widać na przedstawionych mapach ciepła, szybsze tempo zmian środowiska wymaga od osobników silniejszych mutacji aby się dostosować. W naszym modelu tempo ewolucji ma duże znaczenie dla przetrwania populacji doświadczającej nagłych zmian klimatycznych, co jest zgodne z obserwacjami w prawdziwym świecie.

Porównując między sobą pary map ciepła, można dostrzec wyraźne różnice w przebiegu symulacji w zależności od wartości parametru p . Populacje, w których $p = p_{max}$ mają gor-



Rysunek 6: Mapy ciepła średniej i odchylenia standardowego fitness w symulacjach prowadzonych przy $p = p_{max}$

sze dostosowanie od tych, w których $p = 1$. Nie jest to jednak spowodowane przez dryf genetyczny, po prostu populacje z mniejszym prawdopodobieństwem rozrodu pojedynczego osobnika (0.2973 to dużo mniej niż 1) znacznie szybciej wymiera. Na podstawie powyższej analizy, doszliśmy do wniosku, że schemat reprodukcji nie ma większego znaczenia w przypadku dostosowywania się populacji do gwałtownych zmian klimatu.